Laboratorio 5 - Representaciones Vectoriales de Texto

Francisco Castillo - 21562

1. Preprocesamiento del corpus

```
In [1]: from sklearn.datasets import fetch 20newsgroups
        import re
        import nltk
        nltk.download('punkt', quiet=True)
        nltk.download('stopwords', quiet=True)
        nltk.download('wordnet', quiet=True)
        nltk.download('punkt_tab', quiet=True)
        from nltk.corpus import stopwords
        from nltk.stem import WordNetLemmatizer
        from sklearn.model_selection import train_test_split
In [2]: categories=['talk.politics.guns', 'talk.politics.mideast', 'talk.politics.misc', 'rec.autos']
        news = fetch 20newsgroups(subset='all', categories=categories, remove=('headers', 'footers', 'quotes'), shuffle=True
In [3]: def preprocess text(text):
            text = text.lower()
            text = re.sub(r'[^a-z\s]', '', text)
            # Remove sequences of repeated characters or potential artifacts like 'outofcontrolgif' and the subsequent random
            text = re.sub(r'\b\w*outofcontrolgif\w*\b', '', text) # Remove the specific 'outofcontrolgif' word and any attack
            text = re.sub(r'\b[a-z]{15,}\b', '', text) # Remove words that are 15 or more characters long and consist only of
            return text
In [4]: preprocessed news = [preprocess text(doc) for doc in news.data]
        tokenized_news = [nltk.word_tokenize(doc) for doc in preprocessed_news]
        # Remove tokens starting with "begin"
        tokenized news = [[word for word in doc if not word.startswith('begin')] for doc in tokenized news]
```

```
In [5]: for i in range(10):
    print(tokenized_news[i])
```

['what', 'say', 'you', 'and', 'nick', 'go', 'somewhere', 'else', 'with', 'this', 'shool', 'yard', 'crap'] ['in', 'europe', 'you', 'can', 'buy', 'a', 'ix', 'with', 'computer', 'controlled', 'diffs', 'rather', 'than', 'the', 'horrid', 'viscous', 'coupled', 'ones', 'of', 'the', 'outgoing', 'ix'] ['i', 'dont', 'think', 'weve', 'got', 'a', 'conspiracy', 'on', 'our', 'hands', 'or', 'anything', 'vaugely', 'simila r', 'i', 'do', 'think', 'that', 'the', 'feds', 'showed', 'a', 'distinct', 'lack', 'of', 'both', 'intelligence', 'an d', 'disregard', 'for', 'others', 'safety', 'throughout', 'this', 'whole', 'mess', 'i', 'do', 'think', 'the', 'fbi', 'and', 'the', 'batf', 'screwed', 'up', 'big', 'what', 'made', 'me', 'really', 'concerned', 'was', 'fbi', 'director', 'william', 'sessions', 'being', 'on', 'cnn', 'engaging', 'in', 'what', 'could', 'only', 'be', 'called', 'spin', 'cont rol', 'before', 'the', 'place', 'had', 'even', 'cooled', 'down', 'evertyhing', 'had', 'literally', 'blown', 'up', 'i n', 'their', 'faces', 'and', 'i', 'felt', 'there', 'had', 'to', 'be', 'something', 'more', 'important', 'he', 'shoul d', 'have', 'been', 'doing'] ['mfehaeqkkl', 'mgfqqloozfemdj', 'lzylluke', 'end'] ['for', 'starters', 'they', 'could', 'have', 'gone', 'on', 'waiting', 'and', 'negotiating', 'the', 'davidians', 'were nt', 'going', 'anywhere', 'and', 'their', 'supplies', 'had', 'to', 'be', 'limited', 'large', 'perhaps', 'but', 'limit ed', 'if', 'they', 'had', 'simply', 'fired', 'the', 'compound', 'by', 'themselves', 'without', 'govt', 'tanks', 'smas hing', 'down', 'their', 'walls', 'then', 'at', 'least', 'the', 'govt', 'would', 'not', 'be', 'guilty', 'of', 'havin g', 'again', 'used', 'an', 'inappropriate', 'level', 'of', 'force', 'and', 'would', 'have', 'been', 'able', 'to', 'us e', 'the', 'meantime', 'to', 'continue', 'to', 'pressure', 'and', 'negotiate', 'no', 'they', 'would', 'not', 'have', 'looked', 'good', 'on', 'the', 'news', 'in', 'six', 'months', 'or', 'a', 'year', 'but', 'they', 'sure', 'as', 'hell', 'dont', 'look', 'very', 'good', 'now', 'larry', 'smith', 'smithctroncom', 'no', 'i', 'dont', 'speak', 'for', 'cabletr on', 'need', 'you', 'ask'] ['is', 'this', 'a', 'joke'] ['hi', 'maybe', 'someone', 'can', 'help', 'me', 'here', 'i', 'am', 'looking', 'to', 'buy', 'this', 'nissan', 'maxim a', 'gxe', 'for', 'cdn', 'right', 'now', 'the', 'car', 'has', 'km', 'or', 'about', 'miles', 'on', 'it', 'a', 'typica l', 'mileage', 'for', 'cars', 'seem', 'to', 'be', 'about', 'km', 'or', 'about', 'k', 'mi', 'the', 'seller', 'just', 'informed', 'me', 'that', 'when', 'he', 'brought', 'the', 'car', 'in', 'for', 'certification', 'he', 'was', 'told', 'that', 'the', 'front', 'break', 'pads', 'and', 'the', 'exhausts', 'had', 'to', 'be', 'replaced', 'to', 'meet', 'th e', 'legal', 'standards', 'he', 'said', 'he', 'will', 'replace', 'the', 'components', 'before', 'selling', 'the', 'ca r', 'to', 'me', 'being', 'copmletely', 'ignorant', 'to', 'the', 'technical', 'stuff', 'on', 'cars', 'i', 'dont', 'kno w', 'what', 'this', 'could', 'mean', 'is', 'k', 'km', 'about', 'the', 'time', 'typical', 'for', 'replacing', 'the', 'above', 'mentioned', 'items', 'or', 'is', 'this', 'an', 'indication', 'that', 'the', 'car', 'was', 'abused', 'woul d', 'other', 'things', 'break', 'down', 'or', 'have', 'to', 'be', 'replaced', 'soon', 'the', 'seller', 'told', 'me', 'that', 'he', 'used', 'the', 'car', 'on', 'the', 'highway', 'a', 'lot', 'but', 'i', 'dont', 'know', 'how', 'to', 'ver ify', 'this', 'ive', 'seen', 'the', 'paint', 'chipped', 'away', 'in', 'tiny', 'dots', 'in', 'the', 'front', 'edge', 'of', 'the', 'hood', 'though', 'although', 'the', 'maxima', 'is', 'an', 'excellent', 'car', 'and', 'the', 'car', 'i s', 'very', 'clean', 'and', 'well', 'kept', 'its', 'currently', 'out', 'of', 'warranty', 'a', 'similarly', 'priced', 'accord', 'with', 'k', 'km', 'will', 'have', 'years', 'or', 'k', 'km', 'worth', 'of', 'warranty', 'left', 'and', 'i', 'dont', 'want', 'to', 'worry', 'about', 'paying', 'for', 'any', 'repair', 'bills', 'but', 'i', 'also', 'need', 'a', 'car', 'for', 'people', 'when', 'will', 'the', 'new', 'maxima', 'come', 'out', 'by', 'the', 'way', 'i', 'would', 'ver y', 'much', 'appreciate', 'your', 'input', 'in', 'this', 'please', 'reply', 'by', 'email', 'preferred', 'or', 'post', 'in', 'this', 'newsgroup', 'thanks', 'ryan'] ['watch', 'the', 'videotape', 'carefully', 'the', 'cnn', 'coverage', 'was', 'fairly', 'decisive', 'the', 'first', 'fi

re', 'starts', 'in', 'the', 'tower', 'this', 'is', 'three', 'storeys', 'high', 'and', 'there', 'is', 'a', 'flag', 't o', 'the', 'right', 'of', 'it', 'on', 'the', 'picture', 'the', 'second', 'fire', 'starts', 'in', 'another', 'tower', 'which', 'is', 'similar', 'to', 'the', 'first', 'only', 'two', 'storeys', 'high', 'the', 'flag', 'is', 'on', 'the', 'left', 'in', 'the', 'camera', 'picture', 'that', 'shows', 'this', 'fire', 'starting', 'thus', 'the', 'camera', 'pict ures', 'cleraly', 'show', 'the', 'fire', 'starting', 'at', 'two', 'separate', 'locations', 'the', 'fbi', 'report', 'a', 'third', 'i', 'was', 'not', 'able', 'to', 'verify', 'it', 'from', 'the', 'videotape', 'however', 'someone', 'els e', 'identified', 'a', 'fire', 'shown', 'to', 'be', 'starting', 'behind', 'the', 'small', 'tower', 'in', 'the', 'seco nd', 'flag', 'on', 'left', 'camera', 'angle', 'the', 'flames', 'coming', 'out', 'of', 'the', 'building', 'are', 'yell oworange', 'this', 'is', 'the', 'normal', 'colour', 'for', 'carbon', 'compounds', 'burning', 'the', 'flames', 'were', 'those', 'of', 'a', 'solid', 'or', 'confined', 'liquid', 'burning', 'not', 'of', 'a', 'gas', 'exploding', 'the', 'exp losion', 'that', 'occurs', 'mid', 'way', 'along', 'the', 'building', 'is', 'certainly', 'not', 'an', 'explosive', 'th ough', 'the', 'cloud', 'itself', 'is', 'on', 'fire', 'this', 'would', 'seem', 'to', 'be', 'most', 'likely', 'to', 'b e', 'some', 'sort', 'of', 'fuel', 'oil', 'store', 'exploding', 'rather', 'than', 'the', 'explosion', 'of', 'a', 'maga zine', 'depends', 'entirely', 'on', 'how', 'they', 'were', 'distributed', 'you', 'would', 'not', 'be', 'able', 'to', 'identify', 'ammunition', 'rounds', 'going', 'off', 'from', 'video', 'camera', 'coverage', 'from', 'a', 'mile', 'awa y', 'if', 'and', 'when', 'the', 'fbi', 'release', 'pictures', 'from', 'cmeras', 'on', 'the', 'armoured', 'vehicles', 'which', 'presumably', 'exist', 'it', 'might', 'be', 'possible', 'to', 'get', 'a', 'clearer', 'picture', 'if', 'anyon e', 'expects', 'to', 'see', 'explosions', 'hollywood', 'style', 'aka', 'rambo', 'movies', 'then', 'remember', 'that', 'in', 'real', 'life', 'cars', 'do', 'not', 'burst', 'into', 'flames', 'when', 'going', 'over', 'cliffs', 'just', 'abo ut', 'the', 'most', 'you', 'could', 'expect', 'would', 'be', 'to', 'see', 'the', 'grenades', 'going', 'off', 'since', 'the', 'building', 'was', 'designed', 'to', 'be', 'blast', 'proof', 'to', 'some', 'extent', 'it', 'would', 'be', 'dif ficult', 'to', 'distinguish', 'the', 'grenades', 'going', 'off', 'from', 'the', 'collapse', 'of', 'the', 'building', 'due', 'to', 'the', 'fire', 'paranoia', 'you', 'wouldnt', 'beleive', 'the', 'fbi', 'if', 'they', 'showed', 'you', 'a', 'picture', 'of', 'koresh', 'himself', 'setting', 'light', 'to', 'the', 'place', 'your', 'mindset', 'is', 'such', 'that', 'you', 'are', 'simply', 'unable', 'to', 'accept', 'as', 'true', 'anything', 'that', 'might', 'suggest', 'tha t', 'a', 'group', 'of', 'heavily', 'armed', 'weapons', 'fanatics', 'might', 'indeed', 'be', 'in', 'the', 'wrong', 'th e', 'gun', 'lobby', 'cant', 'accept', 'that', 'the', 'bd', 'set', 'light', 'to', 'the', 'place', 'because', 'that', 'would', 'mean', 'that', 'koreh', 'had', 'murdered', 'children', 'that', 'would', 'mean', 'that', 'their', 'taking', 'his', 'account', 'of', 'the', 'murder', 'of', 'batf', 'agents', 'would', 'be', 'even', 'less', 'credible', 'than', 'it', 'was', 'to', 'start', 'with', 'koresh', 'had', 'days', 'to', 'come', 'out', 'with', 'his', 'hands', 'up', 'an d', 'face', 'a', 'fair', 'trial', 'instead', 'he', 'ordered', 'the', 'murder', 'of', 'everyone', 'in', 'the', 'plac e'] ['my', 'wife', 'rarely', 'carries', 'a', 'purse', 'so', 'all', 'of', 'her', 'crap', 'ends', 'up', 'in', 'my', 'pocket s']

En el preprocesamiento eliminamos lo que parecen ser diferentes gifs e imagenes que contienen cadenas de texto "aleatorias" y pueden alterar el desempeño de la vectorización.

```
In [6]: stop_words = set(stopwords.words('english'))
lemmatizer = WordNetLemmatizer()
```

```
def remove_stopwords_and_lemmatize(tokens):
    return [lemmatizer.lemmatize(word) for word in tokens if word not in stop_words]

tokenized_news_cleaned = [remove_stopwords_and_lemmatize(doc) for doc in tokenized_news]

# Remove empty documents and their corresponding labels
non_empty_indices = [i for i, doc in enumerate(tokenized_news_cleaned) if doc]
tokenized_news_cleaned = [tokenized_news_cleaned[i] for i in non_empty_indices]
cleaned_target = [news.target[i] for i in non_empty_indices]
```

```
In [7]: for i in range(10):
    print(tokenized_news_cleaned[i])
```

```
['say', 'nick', 'go', 'somewhere', 'else', 'shool', 'yard', 'crap']
['europe', 'buy', 'ix', 'computer', 'controlled', 'diffs', 'rather', 'horrid', 'viscous', 'coupled', 'one', 'outgoin
g', 'ix']
['dont', 'think', 'weve', 'got', 'conspiracy', 'hand', 'anything', 'vaugely', 'similar', 'think', 'fed', 'showed', 'd
istinct', 'lack', 'intelligence', 'disregard', 'others', 'safety', 'throughout', 'whole', 'mess', 'think', 'fbi', 'ba
tf', 'screwed', 'big', 'made', 'really', 'concerned', 'fbi', 'director', 'william', 'session', 'cnn', 'engaging', 'co
uld', 'called', 'spin', 'control', 'place', 'even', 'cooled', 'evertyhing', 'literally', 'blown', 'face', 'felt', 'so
mething', 'important']
['mfehaeqkkl', 'mgfqqloozfemdj', 'lzylluke', 'end']
['starter', 'could', 'gone', 'waiting', 'negotiating', 'davidians', 'werent', 'going', 'anywhere', 'supply', 'limite
d', 'large', 'perhaps', 'limited', 'simply', 'fired', 'compound', 'without', 'govt', 'tank', 'smashing', 'wall', 'lea
st', 'govt', 'would', 'guilty', 'used', 'inappropriate', 'level', 'force', 'would', 'able', 'use', 'meantime', 'conti
nue', 'pressure', 'negotiate', 'would', 'looked', 'good', 'news', 'six', 'month', 'year', 'sure', 'hell', 'dont', 'lo
ok', 'good', 'larry', 'smith', 'smithctroncom', 'dont', 'speak', 'cabletron', 'need', 'ask']
['joke']
['hi', 'maybe', 'someone', 'help', 'looking', 'buy', 'nissan', 'maximum', 'gxe', 'cdn', 'right', 'car', 'km', 'mile',
'typical', 'mileage', 'car', 'seem', 'km', 'k', 'mi', 'seller', 'informed', 'brought', 'car', 'certification', 'tol
d', 'front', 'break', 'pad', 'exhaust', 'replaced', 'meet', 'legal', 'standard', 'said', 'replace', 'component', 'sel
ling', 'car', 'copmletely', 'ignorant', 'technical', 'stuff', 'car', 'dont', 'know', 'could', 'mean', 'k', 'km', 'tim
e', 'typical', 'replacing', 'mentioned', 'item', 'indication', 'car', 'abused', 'would', 'thing', 'break', 'replace
d', 'soon', 'seller', 'told', 'used', 'car', 'highway', 'lot', 'dont', 'know', 'verify', 'ive', 'seen', 'paint', 'chi
pped', 'away', 'tiny', 'dot', 'front', 'edge', 'hood', 'though', 'although', 'maximum', 'excellent', 'car', 'c
lean', 'well', 'kept', 'currently', 'warranty', 'similarly', 'priced', 'accord', 'k', 'km', 'year', 'k', 'km', 'wort
h', 'warranty', 'left', 'dont', 'want', 'worry', 'paying', 'repair', 'bill', 'also', 'need', 'car', 'people', 'new',
'maximum', 'come', 'way', 'would', 'much', 'appreciate', 'input', 'please', 'reply', 'email', 'preferred', 'post', 'n
ewsgroup', 'thanks', 'ryan']
['watch', 'videotape', 'carefully', 'cnn', 'coverage', 'fairly', 'decisive', 'first', 'fire', 'start', 'tower', 'thre
e', 'storey', 'high', 'flag', 'right', 'picture', 'second', 'fire', 'start', 'another', 'tower', 'similar', 'first',
'two', 'storey', 'high', 'flag', 'left', 'camera', 'picture', 'show', 'fire', 'starting', 'thus', 'camera', 'pictur
e', 'cleraly', 'show', 'fire', 'starting', 'two', 'separate', 'location', 'fbi', 'report', 'third', 'able', 'verify',
'videotape', 'however', 'someone', 'else', 'identified', 'fire', 'shown', 'starting', 'behind', 'small', 'tower', 'se
cond', 'flag', 'left', 'camera', 'angle', 'flame', 'coming', 'building', 'yelloworange', 'normal', 'colour', 'carbo
n', 'compound', 'burning', 'flame', 'solid', 'confined', 'liquid', 'burning', 'gas', 'exploding', 'explosion', 'occur
s', 'mid', 'way', 'along', 'building', 'certainly', 'explosive', 'though', 'cloud', 'fire', 'would', 'seem', 'likel
y', 'sort', 'fuel', 'oil', 'store', 'exploding', 'rather', 'explosion', 'magazine', 'depends', 'entirely', 'distribut
ed', 'would', 'able', 'identify', 'ammunition', 'round', 'going', 'video', 'camera', 'coverage', 'mile', 'away', 'fb
i', 'release', 'picture', 'cmeras', 'armoured', 'vehicle', 'presumably', 'exist', 'might', 'possible', 'get', 'cleare
r', 'picture', 'anyone', 'expects', 'see', 'explosion', 'hollywood', 'style', 'aka', 'rambo', 'movie', 'remember', 'r
eal', 'life', 'car', 'burst', 'flame', 'going', 'cliff', 'could', 'expect', 'would', 'see', 'grenade', 'going', 'sinc
e', 'building', 'designed', 'blast', 'proof', 'extent', 'would', 'difficult', 'distinguish', 'grenade', 'going', 'col
lapse', 'building', 'due', 'fire', 'paranoia', 'wouldnt', 'beleive', 'fbi', 'showed', 'picture', 'koresh', 'setting',
'light', 'place', 'mindset', 'simply', 'unable', 'accept', 'true', 'anything', 'might', 'suggest', 'group', 'heavil
```

```
y', 'armed', 'weapon', 'fanatic', 'might', 'indeed', 'wrong', 'gun', 'lobby', 'cant', 'accept', 'bd', 'set', 'light', 'place', 'would', 'mean', 'koreh', 'murdered', 'child', 'would', 'mean', 'taking', 'account', 'murder', 'batf', 'agen t', 'would', 'even', 'less', 'credible', 'start', 'koresh', 'day', 'come', 'hand', 'face', 'fair', 'trial', 'instea d', 'ordered', 'murder', 'everyone', 'place']
['wife', 'rarely', 'carry', 'purse', 'crap', 'end', 'pocket']
['oh', 'ok', 'wondering', 'real', 'expert', 'weapon', 'wondering', 'would', 'job']
```

También, dado que no generaremos texto procedemos a lematizar y eliminar las stopwords para obtener mejor precisión.

```
In [8]: X_train, X_test, y_train, y_test = train_test_split(tokenized_news_cleaned, cleaned_target, test_size=0.25, random_st
    print(f"Training set size: {len(X_train)}")
    print(f"Testing set size: {len(X_test)}")
```

Training set size: 2616 Testing set size: 873

2. Construcción de representación TF-IDF

```
for i in range(5):
     print(f"\n--- Document {i+1} ---")
     tfidf_row = X_train_tfidf[i].toarray()[0]
     top_words = get_top_tfidf_words(tfidf_row, feature_names)
     for word, score in top_words:
         print(f"{word}: {score:.4f}")
--- Document 1 ---
ohio: 0.2662
frank: 0.2662
bad: 0.2527
regardless: 0.2220
trial: 0.2107
--- Document 2 ---
serb: 0.6182
muslim: 0.3360
bosnian: 0.2662
serbia: 0.2124
refused: 0.1876
--- Document 3 ---
being: 0.2249
automobile: 0.2039
honest: 0.2028
value: 0.1680
criminal: 0.1600
--- Document 4 ---
gun: 0.3145
shoot: 0.2573
sw: 0.2199
training: 0.2163
revolver: 0.1899
```

--- Document 5 ---

slip: 0.4499 tranny: 0.2771 gear: 0.2504 usually: 0.2110 speed: 0.2104

Palabras con mayor peso

Las palabras con más peso (los scores TF-IDF más altos) en un documento particular son aquellas que son importantes dentro de ese documento y, al mismo tiempo, no son muy comunes en el resto del corpus. Esto significa que esas palabras son las que mejor representan o distinguen el tema o contenido específico de ese documento en comparación con otros documentos. Por ejemplo, en el "Documento 2", palabras como "serb", "muslim", "bosnian" y "serbia" tienen altos pesos, lo que sugiere que este documento trata sobre el conflicto en los Balcanes. De manera similar, en el "Documento 4", términos como "gun", "shoot", "training" y "revolver" indican claramente que el documento está relacionado con el tema de las armas. En resumen, estos altos pesos nos señalan las palabras clave que son muy relevantes y distintivas para cada documento particular.

Limitaciones semánticas de TF-IDF

TF-IDF se basa únicamente en la frecuencia y rareza de las palabras, sin considerar su significado o el contexto en el que aparecen. Al tratar los documentos como una "bolsa de palabras", ignora el orden y las relaciones entre ellas, lo que impide capturar sinónimos, polisemia o relaciones semánticas más profundas. Esto significa que, aunque identifica palabras clave relevantes, no comprende el sentido completo ni las conexiones entre las ideas en un texto.

3. Construcción de Representación PPMI

```
In [13]: from collections import defaultdict
import pandas as pd
from scipy.sparse import lil_matrix

def build_cooccurrence_matrix(tokenized_docs, window_size):
    word_counts = defaultdict(int)
    cooccurrence_counts = defaultdict(lambda: defaultdict(int))

for doc in tokenized_docs:
    for i, target_word in enumerate(doc):
        word_counts[target_word] += 1
        start_index = max(0, i - window_size)
        end_index = min(len(doc), i + window_size + 1)

for j in range(start_index, end_index):
        if i != j:
```

```
In [14]: import numpy as np
         def calculate_ppmi(cooccurrence_matrix, vocabulary):
             total_pairs = cooccurrence_matrix.sum()
             word_sums = cooccurrence_matrix.sum(axis=1).A1 # Sum of each row (target words)
             context_sums = cooccurrence_matrix.sum(axis=0).A1 # Sum of each column (context words)
             ppmi matrix = lil matrix(cooccurrence matrix.shape, dtype=float)
             rows, cols = cooccurrence_matrix.nonzero() # Get indices of non-zero elements
             for row, col in zip(rows, cols):
                 cooc_count = cooccurrence_matrix[row, col]
                 p_target_context = cooc_count / total_pairs
                 p_target = word_sums[row] / total_pairs
                 p_context = context_sums[col] / total_pairs
                 # Handle cases to avoid division by zero or log of zero
                 if p_target > 0 and p_context > 0:
                     pmi = np.log2(p_target_context / (p_target * p_context))
                     ppmi = max(0, pmi)
                     ppmi_matrix[row, col] = ppmi
                 else:
                     ppmi_matrix[row, col] = 0
```

```
return ppmi matrix
         cooccurrence matrix, vocabulary = build cooccurrence matrix(tokenized news cleaned, window size=4)
In [15]:
         ppmi_matrix = calculate_ppmi(cooccurrence_matrix, vocabulary)
         print("PPMI Matrix Shape:", ppmi_matrix.shape)
        PPMI Matrix Shape: (29942, 29942)
         4. Construcción de representación Word2Vec
         from gensim.models import Word2Vec
In [16]: vector size = 100 # Dimension of the word vectors
         window = 5
                        # Context window size
         min_count = 5  # Ignore words with frequency lower than this
         workers = 4
                        # Number of CPU cores to use
         epochs = 10
In [17]: | pip install gensim
        Requirement already satisfied: gensim in /usr/local/lib/python3.11/dist-packages (4.3.3)
        Requirement already satisfied: numpy<2.0,>=1.18.5 in /usr/local/lib/python3.11/dist-packages (from gensim) (1.26.4)
        Requirement already satisfied: scipy<1.14.0,>=1.7.0 in /usr/local/lib/python3.11/dist-packages (from gensim) (1.13.1)
        Requirement already satisfied: smart-open>=1.8.1 in /usr/local/lib/python3.11/dist-packages (from gensim) (7.3.0.post
        1)
        Requirement already satisfied: wrapt in /usr/local/lib/python3.11/dist-packages (from smart-open>=1.8.1->gensim) (1.1
        7.3)
In [18]: from gensim.models import Word2Vec
         model = Word2Vec(vector_size=vector_size, window=window, min_count=min_count, workers=workers)
         model.build_vocab(tokenized_news_cleaned)
         total_examples = model.corpus_count
         model.train(tokenized_news_cleaned, total_examples=total_examples, epochs=epochs)
Out[18]: (3818409, 4240950)
In [19]: import numpy as np
```

```
def document vector(doc, model):
             word vectors = []
             for word in doc:
                 # Check if the word exists in the Word2Vec model's vocabulary
                 if word in model.wv.key_to_index:
                     # If the word is in the vocabulary, retrieve its vector using model.wv[word] and append it to the list of
                     word vectors.append(model.wv[word])
             if word_vectors:
                 return np.mean(word vectors, axis=0)
             else:
                 return np.zeros(model.vector_size)
         document_embeddings = [document_vector(doc, model) for doc in tokenized_news_cleaned]
In [20]:
         document_embeddings = np.array(document_embeddings)
         print(document_embeddings.shape)
        (3489, 100)
In [21]: words_to_explore = ['jew', 'christian', 'muslim', 'police']
         print("--- Words Most Similar ---")
         for word in words to explore:
             if word in model.wv:
                 print(f"\nWords similar to '{word}':")
                 similar_words = model.wv.most_similar(word, topn=5)
                 for sim_word, score in similar_words:
                     print(f" {sim_word}: {score:.4f}")
             else:
                 print(f"'{word}' not found in vocabulary.")
         # Calculate similarity between word pairs
         word_pairs = [('gun', 'shoot'), ('car', 'wheel'), ('politics', 'mideast')]
         print("\n--- Word Pair Similarities ---")
         for word1, word2 in word pairs:
             if word1 in model.wv and word2 in model.wv:
                 similarity_score = model.wv.similarity(word1, word2)
                 print(f"Similarity between '{word1}' and '{word2}': {similarity_score:.4f}")
```

```
else:
         print(f"One or both words ('{word1}', '{word2}') not found in vocabulary.")
--- Words Most Similar ---
Words similar to 'jew':
  christian: 0.8579
  wwii: 0.8252
  jewish: 0.8184
  holocaust: 0.7992
  gaza: 0.7969
Words similar to 'christian':
  wwii: 0.9240
  extermination: 0.9200
  croatia: 0.9177
  islam: 0.9113
  hatred: 0.9106
Words similar to 'muslim':
  croat: 0.9609
  bosnian: 0.9478
  serb: 0.9012
  ethnically: 0.8858
  exterminated: 0.8799
Words similar to 'police':
  officer: 0.8381
  agent: 0.8106
  charge: 0.7711
  local: 0.7474
  sheriff: 0.7438
--- Word Pair Similarities ---
Similarity between 'gun' and 'shoot': 0.5484
Similarity between 'car' and 'wheel': 0.8818
Similarity between 'politics' and 'mideast': 0.8180
```

5. Evaluación Comparativa

```
In [22]: from sklearn.linear model import LogisticRegression
         from sklearn.model selection import GridSearchCV
In [23]: param grid = {
             'C': [0.01, 0.1, 1, 10],
              'penalty': ['12']
In [24]: def train_model(X_train, y_train, X_test, y_test, param_grid):
             logistic regression = LogisticRegression(max iter=1000)
             grid search = GridSearchCV(estimator=logistic regression, param grid=param grid, scoring='precision weighted', cv
             grid_search.fit(X_train, y_train)
             print("Best parameters found:")
             print(grid search.best params )
             precision score = grid search.score(X test, y test)
             print(f"Precision: {precision score:.4f}")
             return grid search
In [25]: print("--- TF-IDF ---")
         grid_search_tfidf = train_model(X_train_tfidf, y_train, X_test_tfidf, y_test, param_grid)
        --- TF-TDF ---
        /usr/local/lib/python3.11/dist-packages/sklearn/metrics/ classification.py:1565: UndefinedMetricWarning: Precision is
        ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero division` parameter to control this b
        ehavior.
          warn prf(average, modifier, f"{metric.capitalize()} is", len(result))
        /usr/local/lib/python3.11/dist-packages/sklearn/metrics/ classification.py:1565: UndefinedMetricWarning: Precision is
        ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero division` parameter to control this b
        ehavior.
          warn prf(average, modifier, f"{metric.capitalize()} is", len(result))
        /usr/local/lib/python3.11/dist-packages/sklearn/metrics/ classification.py:1565: UndefinedMetricWarning: Precision is
        ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero division` parameter to control this b
        ehavior.
          warn prf(average, modifier, f"{metric.capitalize()} is", len(result))
        Best parameters found:
        {'C': 10, 'penalty': '12'}
        Precision: 0.8470
```

```
In [26]: word_to_index = {word: i for i, word in enumerate(vocabulary)}
         def document_vector_ppmi(doc, ppmi_matrix, word_to_index):
             word_vectors = []
             for word in doc:
                 if word in word_to_index:
                     word_index = word_to_index[word]
                     word_vector = ppmi_matrix[word_index, :].toarray().flatten()
                     word_vectors.append(word_vector)
             if word_vectors:
                 return np.mean(word_vectors, axis=0)
             else:
                 return np.zeros(ppmi_matrix.shape[1])
         ppmi_document_representations = [document_vector_ppmi(doc, ppmi_matrix, word_to_index) for doc in tokenized_news_clear
In [27]:
         ppmi document representations = np.array(ppmi document representations)
         X_train_ppmi, X_test_ppmi, y_train_check, y_test_check = train_test_split(
             ppmi document representations,
             cleaned_target,
             test size=0.25,
             random state=21562
In [28]: print("\n--- Training Logistic Regression with PPMI ---")
         grid_search_ppmi = train_model(X_train_ppmi, y_train, X_test_ppmi, y_test, param_grid)
        --- Training Logistic Regression with PPMI ---
        Best parameters found:
        {'C': 0.01, 'penalty': '12'}
        Precision: 0.8344
In [29]: X_train_w2v, X_test_w2v, y_train_check_w2v, y_test_check_w2v = train_test_split(
             document embeddings,
             cleaned target,
             test_size=0.25,
             random state=21562
         print("\n--- Word2Vec ---")
         grid_search_w2v = train_model(X_train_w2v, y_train, X_test_w2v, y_test, param_grid)
```

```
--- Word2Vec ---
Best parameters found:
{'C': 10, 'penalty': '12'}
Precision: 0.7884

In [30]: best_precision_tfidf = grid_search_tfidf.best_score_
best_precision_ppmi = grid_search_ppmi.best_score_
best_precision_w2v = grid_search_w2v.best_score_

print("\n--- Model Precision Comparison ---")
print(f"TF-IDF Model Best Precision: {best_precision_tfidf:.4f}")
print(f"PPMI Model Best Precision: {best_precision_ppmi:.4f}")
print(f"Word2Vec Model Best Precision: {best_precision_w2v:.4f}")

--- Model Precision Comparison ---
TF-IDF Model Best Precision: 0.8397
PPMI Model Best Precision: 0.8186
Word2Vec Model Best Precision: 0.7766
```

La representación TF-IDF logró el mejor rendimiento (0.8397), seguida por PPMI (0.8186) y finalmente Word2Vec (0.7766). Este orden podría parecer inicialmente sorprendente, ya que Word2Vec y PPMI tienen la capacidad de capturar relaciones semánticas que TF-IDF no. Sin embargo, para una tarea de clasificación de noticias como esta, la importancia distintiva de las palabras clave (capturada efectivamente por TF-IDF) puede ser un factor más determinante que las relaciones semánticas finas. Es posible que las categorías de noticias seleccionadas estén bien diferenciadas por la presencia de términos específicos que aparecen con alta frecuencia en una categoría y baja en otras. Además, el rendimiento de Word2Vec puede depender mucho de la calidad de los embeddings entrenados con un corpus particular y del método utilizado para agregarlos a nivel de documento (como el promedio de vectores).

6. Discusión Final

Cómo cada representación captura (o no) relaciones semánticas

TF-IDF no captura directamente relaciones semánticas, ya que se enfoca en la importancia de una palabra dentro de un documento en relación con su frecuencia en todo el corpus, sin considerar el contexto o el significado de las palabras. PPMI captura relaciones semánticas de coexistencia o asociación entre palabras basándose en la frecuencia con la que aparecen juntas dentro de una ventana de contexto; un PPMI alto indica una fuerte asociación. Por otro lado, Word2Vec captura relaciones semánticas más ricas al representar palabras en un espacio vectorial continuo donde palabras con significados similares o que aparecen en contextos

similares tienen vectores cercanos; permite capturar relaciones como analogías ("rey" - "hombre" + "mujer" ≈ "reina"). Aunque en este caso particular TF-IDF tuvo la mejor precisión, la capacidad de PPMI y Word2Vec para capturar asociaciones y significados a menudo es crucial para tareas que requieren una comprensión semántica más profunda.

¿En que escenarios es más útil cada técnica?

TF-IDF es especialmente útil en escenarios donde la relevancia de un documento se basa en la presencia de palabras clave distintivas y no tanto en las relaciones semánticas complejas, como en sistemas de recuperación de información, motores de búsqueda simples o filtrado de spam. PPMI es valioso para tareas que analizan la co-ocurrencia de palabras para entender asociaciones, construir diccionarios de sinónimos o realizar análisis de sentimientos basados en palabras adyacentes. Word2Vec es muy efectivo en aplicaciones donde es fundamental capturar el significado y las relaciones semánticas entre palabras y documentos, como en la traducción automática, recomendación de contenido, análisis de similitud semántica de documentos, o como capa de entrada para modelos de deep learning.

¿Cuáles son las limitaciones prácticas (memoria, tiempo de cómputo, interoperabilidad)?

Las representaciones TF-IDF y PPMI pueden resultar en matrices muy grandes y dispersas (con muchos ceros) para vocabularios extensos, lo que puede consumir mucha memoria y ser ineficiente computacionalmente para ciertas operaciones. El cálculo de la matriz de co-ocurrencia para PPMI puede ser costoso en tiempo, especialmente con ventanas de contexto amplias. Word2Vec produce vectores densos de menor dimensión, lo que generalmente reduce los requisitos de memoria y hace las operaciones posteriores más rápidas; sin embargo, el entrenamiento del modelo Word2Vec en grandes corpus puede ser computacionalmente intensivo. En cuanto a la interoperabilidad, las matrices TF-IDF y PPMI están ligadas al corpus con el que fueron creadas, mientras que los embeddings de Word2Vec pueden ser pre-entrenados en corpus masivos y reutilizados en diferentes tareas y dominios, ofreciendo mayor interoperabilidad.